TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

MACROAREA DI SCIENZE MATEMATICHE, FISICHE E NATURALI

CORSO DI LAUREA MAGISTRALE IN BIOINFORMATICA

Progetto “Basi di dati e di conoscenza”

ResistanceBase

Alice Romeo

Matricola: 0257388

Anno Accademico 2018-2019

INDICE

1. STUDIO DI FATTIBILITÀ 3
2. RACCOLTA E ANALISI DEI REQUISITI 3
2.1 Linguaggio Naturale 3
2.2 Glossario dei Termini 4
2.3 Strutturazione dei Requisiti 6
3. DOCUMENTAZIONE 9
4. RISOLUZIONE DELLE GENERALIZZAZIONI 13
5. SCHEMI E-R 15
5,1 Schema E-R logico 15
5.2 Schema E-R con risoluzione delle generalizzazioni 16
5.3 Schema E-R fisico 17
5.3.1 Commenti sullo schema E-R 18
6. TRADUZIONE DELLO SCHEMA E-R FISICO NEL MODELLO RELAZIONALE 18
7. CREAZIONE DEL DATABASE 19
8. INSERIMENTO DEI DATI 23
9. QUERY 24
10. QUERY IN ALGEBRA RELAZIONALE E CALCOLO RELAZIONALE 34

1. STUDIO DI FATTIBILITÀ

In questo progetto è stato creato un database, chiamato **ResistanceBase**, allo scopo di creare uno strumento di consultazione che gestisca le informazioni sugli antibiotici in utilizzo e le tipologie di mutazioni di resistenza ad oggi conosciute associate con la loro inattivazione. Vengono fornite informazioni di base sui singoli antibiotici, sulla loro azione e i *pathway* cellulari in cui sono coinvolti e sui tipi di resistenza da cui sono inattivati. Sono inoltre caratterizzate le sequenze e le relative proteine su cui queste mutazioni si sono verificate e gli organismi batterici di appartenenza. Infine, per ogni tipo di resistenza sono forniti collegamenti con articoli in letteratura.

2. RACCOLTA E ANALISI DEI REQUISITI

2.1 Linguaggio Naturale

Si vuole realizzare una base di dati per raggruppare le informazioni conosciute riguardo gli antibiotici in utilizzo e le mutazioni di resistenza conosciute associate con la loro inefficacia.
I singoli tipi di resistenze vengono identificate da un nome e per ognuna vogliamo conoscerne il tipo di mutazione ("inserzione", "mutazione puntiforme", …), con una breve descrizione del meccanismo molecolare. Si vogliono conoscere le classi di appartenenza dei diversi tipi di resistenze ed i meccanismi con cui i loro effetti si manifestano (uno solo per classe), identificando i singoli meccanismi tramite un codice e fornendo per essi una breve definizione. Un singolo tipo di resistenza appartiene a una sola classe, e tipi di resistenza appartenenti alla stessa classe condividono lo stesso meccanismo di azione. Si vuole inoltre rappresentare il concetto secondo cui alcuni tipi di resistenze, indipendentemente dalla classe di appartenenza, richiedono la contemporanea presenza di un altro tipo di resistenza affinché il loro effetto si possa manifestare.
Per ogni tipo di resistenza vogliamo inoltre avere anche un riferimento ad almeno un articolo scientifico estratto dal database PUBMED NCBI. Ogni articolo è identificato da un ID (PMID) e ne viene riportato inoltre il titolo, il primo autore, l'anno di pubblicazione, la rivista sulla quale è stato pubblicato, il volume, l'*issue* e le pagine.
Ogni tipo di resistenza porta all'inattivazione di uno o più tipi di antibiotici.
Gli antibiotici vengono identificati tramite un codice ATC. Codici ATC a 7 caratteri identificano il singolo antibiotico, codici a 5 caratteri identificano la sottoclasse di appartenenza dell'antibiotico e codici a 4 caratteri rappresentano la classe superiore di appartenenza. Si vuole rappresentare questa gerarchia di classificazione per ogni antibiotico. Per ogni antibiotico si vuole inoltre conoscere il nome, la formula chimica e il peso molecolare (MW). Si vogliono inoltre conoscere i *pathway* cellulari in cui gli antibiotici intervengono. Antibiotici appartenenti alla stessa classe (superiore) intervengono nello stesso *pathway*, e sempre solo in un *pathway*.
Per ogni tipo di resistenza vogliamo avere un collegamento ad una o più sequenze di DNA depositate nel database NCBI su cui questa mutazione è stata ritrovata (da ciò si deduce che ogni sequenza mutata è determinante nell'inattivazione di uno o più antibiotici). Ogni sequenza è identificata da un ID e vogliamo conoscerne il nome e la lunghezza (numero di bp). Si vuole poter distinguere se la sequenza è stata estratta da un cromosoma batterico o da un plasmide, e se la sequenza depositata è completa o no. In una stessa sequenza possono essere presenti più tipi di mutazioni di resistenza, e ogni tipo di mutazione può essere presente in più sequenze.

Ogni sequenza è associata al relativo organismo batterico a cui appartiene, e in cui quindi, è stato riscontrato il tipo di resistenza a cui la sequenza è associata. Per ogni batterio, identificato da un ID, vogliamo conoscere il nome della specie (genere + specie), e il nome della famiglia di appartenenza nell'albero filogenetico.
Per ogni sequenza abbiamo un collegamento a una o più proteine codificate, depositate anch'esse nel database NCBI. Ogni proteina è identificata da un ID e vogliamo inoltre conoscerne il nome, il numero di residui e il peso molecolare. Vogliamo poter distinguere quali delle proteine sono anche degli enzimi. Se una proteina è un enzima, avrà associato un codice di classificazione enzimatica EC (massimo 15 caratteri) specifico per un singolo tipo di enzima (proteine diverse possono appartenere allo stesso tipo enzimatico). Ogni tipo di enzima è a sua volta classificato in un gruppo enzimatico più ampio, identificato da un codice EC a tre caratteri. Per ogni tipo di enzima e per ogni gruppo vogliamo conoscere, oltre al nome, anche la reazione catalizzata. Per ogni gruppo vogliamo anche una breve descrizione.
Si vuole associare ad ogni proteina uno o più ID di *Gene Ontology* che permettono di caratterizzare la funzione della proteina all'interno della cellula attraverso l'utilizzo di termini standard. Ogni ID è associato ad un singolo termine. E' necessario poter distinguere ogni termine come parte di uno solo di tre sotto-gruppi di classificazione: '*cellular component*' (o CC), '*molecular function*' (o MF), `*biological process*' (o BP). Ogni ID può essere associato a più proteine diverse.

2.2 Glossario dei Termini

TERMINE	DESCRIZIONE	COLLEGAMENTI
RESISTENZA	Fenomeno per il quale, a seguito dello sviluppo di una mutazione particolare in un proprio gene, un microrganismo diventa resistente all'azione di uno o più antibiotici con i quali, in precedenza, veniva trattato efficacemente. Vengono suddivise in classi e possono avere un effetto, attraverso vari meccanismi, sull'antibiotico, sul target dell'antibiotico o su entrambi.	Classe di resistenza, articolo, antibiotico, sequenza, resistenze richieste
MUTAZIONE	Modifica stabile ed ereditabile nella sequenza nucleotidica di un genoma dovuta ad agenti esterni o al caso	Resistenza
ANTIBIOTICO	Farmaco in grado di rallentare o bloccare la proliferazione batterica.	Sottoclasse e classe ATC, resistenza, pathway
SEQUENZA	Porzione di genoma (DNA), codificante per una o più proteine, estratta da un organismo, sequenziata e depositata nel database NCBI.	Resistenza, batterio, proteina

PROTEINA	Macromolecola biologica costituita da catene di aminoacidi. Principale componente della cellula, svolge diverse funzioni, che possono essere alterate o inattivate dallo sviluppo di una o più mutazioni nella sequenza genica da cui la proteina viene codificata.	Funzione, codici EC, sequenza
ARTICOLO	Articolo scientifico estratta dal database PUBMED NCBI nel quale viene caratterizzato un tipo e/o una classe di resistenza.	Resistenza
CLASSE ATC	*Anatomical Therapeutic Chemical Classification System* (ATC). Sistema di classificazione gerarchica dei farmaci. In questo database si farà riferimento solo alla categoria di farmaci J ("Anti-infettivi per uso sistemico"), di cui fanno parte gli antibiotici.	Antibiotico, pathway
BATTERIO	Organismo batterico nella cui sequenza di DNA si è sviluppata la mutazione di resistenza per uno o più antibiotici. Le varie specie batteriche vengono classificate in maniera gerarchica attraverso un albero filogenetico (Dominio, Phylum, Classe, Ordine, Famiglia, Genere, Specie)	Sequenza, famiglia
CLASSIFICAZIONE EC	Sistema di classificazione degli enzimi tramite un codice EC (*Enzyme Commission)* sulla base della reazione chimica da essi catalizzata. Il codice completo è composto un prefisso 'EC' e quattro numeri separati da punti, in cui il primo numero rappresenta il gruppo enzimatico generale e gli altri tre dei sottolivelli successivi di classificazione. Il codice completo è associato ad un tipo di enzima specifico.	Proteina
FUNZIONE / GENE ONTOLOGY	Funzione/i della proteina all'interno della cellula. Per descrivere e caratterizzare ogni funzione vengono utilizzati dei termini standard, associati a dei codici identificativi, implementati nel database *Gene*	Proteina

	Ontology (http://geneontology.org/). Ogni termine viene classificato in uno di tre gruppi principali: '*cellular component*' (termini che descrivono parti di una cellula o del suo ambiente extracellulare), '*molecular function*' (termini che descrivono attività elementari di un prodotto genico a livello molecolare), '*biological process*' (termini che descrivono eventi molecolari con un inizio e una fine definiti, pertinenti al funzionamento della cellula).	
PATHWAY	Processi cellulari, comprendenti una serie di interazioni tra molecole, che portano a un certo prodotto finale o a un cambiamento all'interno della cellula.	Antibiotico, classe ATC

2.3 Strutturazione dei Requisiti

Frasi di carattere generale
Si vuole realizzare una base di dati per raggruppare le informazioni conosciute riguardo gli antibiotici in utilizzo e le mutazioni di resistenza conosciute associate con la loro inefficacia.
Frasi relative a 'Resistenza'
▪ I singoli tipi di resistenze vengono identificate da un nome e per ognuna vogliamo conoscerne il tipo di mutazione ("inserzione", "mutazione puntiforme", …), con una breve descrizione del meccanismo molecolare. ▪ Si vogliono conoscere le classi di appartenenza dei diversi tipi di resistenze ed i meccanismi con cui i loro effetti si manifestano (uno solo per classe), identificando i singoli meccanismi tramite un codice e fornendo per essi una breve definizione. ▪ Un singolo tipo di resistenza appartiene a una sola classe, e tipi di resistenza appartenenti alla stessa classe condividono lo stesso meccanismo di azione. ▪ Si vuole inoltre rappresentare il concetto secondo cui alcuni tipi di resistenze, indipendentemente dalla classe di appartenenza, richiedono la contemporanea presenza di un altro tipo di resistenza affinché il loro effetto si possa manifestare. ▪ Per ogni tipo di resistenza vogliamo inoltre avere anche un riferimento ad almeno un articolo scientifico estratto dal database PUBMED NCBI. ▪ Ogni tipo di resistenza porta all'inattivazione di uno o più tipi di antibiotici.
Frasi relative a 'Mutazione'
▪ I singoli tipi di resistenze vengono identificate da un nome e per ognuna vogliamo conoscerne il tipo di mutazione ("inserzione", "mutazione puntiforme", …), con una breve descrizione del meccanismo molecolare.

Frasi relative ad 'Antibiotico'
▪ Ogni tipo di resistenza porta all'inattivazione di uno o più tipi di antibiotici. ▪ Gli antibiotici vengono identificati tramite un codice ATC ▪ Per ogni antibiotico si vuole inoltre conoscere il nome, la formula chimica e il peso molecolare (MW). ▪ Si vogliono inoltre conoscere i *pathway* cellulari in cui gli antibiotici intervengono. Antibiotici appartenenti alla stessa classe (superiore) intervengono nello stesso *pathway*, e sempre solo in un *pathway*.
Frasi relative a 'Sequenza'
▪ Per ogni tipo di resistenza vogliamo avere un collegamento ad una o più sequenze di DNA depositate nel database NCBI su cui questa mutazione è stata ritrovata (da ciò si deduce che ogni sequenza mutata è determinante nell'inattivazione di uno o più antibiotici). ▪ Ogni sequenza è identificata da un ID e vogliamo conoscerne il nome e la lunghezza (numero di bp). ▪ Si vuole poter distinguere se la sequenza è stata estratta da un cromosoma batterico o da un plasmide, e se la sequenza depositata è completa o no. ▪ In una stessa sequenza possono essere presenti più tipi di mutazioni di resistenza, e ogni tipo di mutazione può essere presente in più sequenze. ▪ Ogni sequenza è associata al relativo organismo batterico a cui appartiene, e in cui quindi, è stato riscontrato il tipo di resistenza a cui la sequenza è associata.
Frasi relative a 'Proteina'
▪ Per ogni sequenza abbiamo un collegamento a una o più proteine codificate, depositate anch'esse nel database NCBI. ▪ Ogni proteina è identificata da un ID e vogliamo inoltre conoscerne il nome, il numero di residui e il peso molecolare. ▪ Vogliamo poter distinguere quali delle proteine sono anche degli enzimi. Se una proteina è un enzima, avrà associato un codice di classificazione enzimatica EC (massimo 15 caratteri) specifico per un singolo tipo di enzima (proteine diverse possono appartenere allo stesso tipo enzimatico). ▪ Si vuole associare ad ogni proteina uno o più ID di *Gene Ontology* che permettono di caratterizzare la funzione della proteina all'interno della cellula attraverso l'utilizzo di termini standard. ▪ Ogni ID può essere associato a più proteine diverse.
Frasi relative ad 'Articolo'
▪ Per ogni tipo di resistenza vogliamo inoltre avere anche un riferimento ad almeno un articolo scientifico estratto dal database PUBMED NCBI. ▪ Ogni articolo è identificato da un ID (PMID) e ne viene riportato inoltre il titolo, il primo autore, l'anno di pubblicazione, la rivista sulla quale è stato pubblicato, il volume, l'*issue* e le pagine.
Frasi relative a 'Classe ATC'
▪ Gli antibiotici vengono identificati tramite un codice ATC ▪ Codici ATC a 7 caratteri identificano il singolo antibiotico, codici a 5 caratteri identificano la sottoclasse di appartenenza dell'antibiotico e codici a 4 caratteri rappresentano la classe superiore di appartenenza. Si vuole rappresentare questa gerarchia di classificazione per

ogni antibiotico.
Frasi relative a 'Batterio'
▪ Ogni sequenza è associata al relativo organismo batterico a cui appartiene, e in cui quindi, è stato riscontrato il tipo di resistenza a cui la sequenza è associata. ▪ Per ogni batterio, identificato da un ID, vogliamo conoscere il nome della specie (genere + specie), e il nome della famiglia di appartenenza nell'albero filogenetico.
Frasi relative a 'Classificazione EC'
▪ Se una proteina è un enzima, avrà associato un codice di classificazione enzimatica EC (massimo 15 caratteri) specifico per un singolo tipo di enzima (proteine diverse possono appartenere allo stesso tipo enzimatico). ▪ Ogni tipo di enzima è a sua volta classificato in un gruppo enzimatico più ampio, identificato da un codice EC a tre caratteri. ▪ Per ogni tipo di enzima e per ogni gruppo vogliamo conoscere, oltre al nome, anche la reazione catalizzata. ▪ Per ogni gruppo vogliamo anche una breve descrizione.
Frasi relative a 'Funzione / Gene Ontology'
▪ Si vuole associare ad ogni proteina uno o più ID di *Gene Ontology* che permettono di caratterizzare la funzione della proteina all'interno della cellula attraverso l'utilizzo di termini standard. ▪ Ogni ID è associato ad un singolo termine. ▪ E' necessario poter distinguere ogni termine come parte di uno solo di tre sotto-gruppi di classificazione: '*cellular component*' (o CC), '*molecular function*' (o MF), `*biological process*' (o BP). ▪ Ogni ID può essere associato a più proteine diverse.
Frasi relative a 'Pathway'
▪ Si vogliono inoltre conoscere i *pathway* cellulari in cui gli antibiotici intervengono. Antibiotici appartenenti alla stessa classe (superiore) intervengono nello stesso *pathway*, e sempre solo in un *pathway*.

3. DOCUMENTAZIONE

ENTITA'	DESCRIZIONE	ATTRIBUTI	IDENTIFICATORE
MUT	Tipi di mutazioni che possono verificarsi in una sequenza di DNA	tipo, descr	tipo
FAM	Famiglie dell'albero filogenetico del dominio 'Bacteria'.	fam_id, nome_f	fam_id
BATTERIO	Organismi batterici nei quali sono state ritrovate mutazioni di resistenza.	bat_id, nome_sp	bat_id
MEC	Meccanismi attraverso cui si manifestano gli effetti di una resistenza a un antibiotico.	mec_id, azione	mec_id
GRUPPO	Gruppi di classificazione ('EC'+1 numero) degli enzimi a seconda del tipo di reazione generale catalizzata.	group_id, nome_gr, descr, reaz_gr	group_id
EC	Codici di classificazione enzimatica EC per i singoli tipi di enzimi (massimo 15 caratteri).	ec_id, reazione	ec_id
PATHWAY	*Pathway* cellulari nei quali agiscono gli antibiotici	path_id, azione	path_id
RIV	Volumi, anno di pubblicazione e riviste degli articoli estratti da PUBMED NCBI.	cod, vol, anno, rivista	cod
ART	Articoli estratti da PUBMED NCBI.	pmid, autore, riv, issue, pag, titolo	pmid

CLASSE	Classi di mutazioni di resistenza	class_id	class_id
ATC	Classi superiori di classificazione degli antibiotici (codici a quattro caratteri)	atc_id, nome_atc, target	atc_id
SUBCLASS	Sottoclassi di classificazione degli antibiotici (codici a cinque caratteri)	sub_id, nome	sub_id
ANT	Antibiotici la cui azione viene impedita dalla presenza di mutazioni di resistenza.	ant_id, nome_a, formula, mw	ant_id
RES	Tipi di mutazioni di resistenza conosciute.	res_id	res_id
SEQ	Sequenze di DNA depositate nel database NCBI nelle quali sono state trovate mutazioni di resistenza.	seq_id, nome_s, bp	seq_id
COMPL	Sequenze di DNA depositate complete, ovvero sequenziate completamente	seq_id, nome_s, bp	seq_id
NON_COMP	Sequenze di DNA non depositate complete, ovvero non sequenziate completamente	seq_id, nome_s, bp	seq_id
CHR	Sequenze di DNA derivanti da DNA cromosomale batterico	seq_id, nome_s, bp	seq_id
PLASM	Sequenze di DNA derivanti da DNA plasmidico batterico	seq_id, nome_s, bp	seq_id
PROT	Proteine la cui funzione o struttura è alterata dal verificarsi di mutazioni di resistenza nelle	prot_id, nome_pr, residui, mw	prot_id

	sequenze di DNA da cui sono codificate		
ENZIMI	Proteine che hanno funzione enzimatica	prot_id, nome_pr, residui, mw	prot_id
FUNZ	Codici identificativi derivanti da database di *Gene Ontology* (http://geneontology.org/) e relativi termini associati, caratterizzanti la funzione di una proteina all'interno della cellula.	funz_id, term	funz_id
CELL_COMP	Termini che descrivono parti di una cellula o dal suo ambiente extracellulare (es. 'Proteina transmembrana')	funz_id, term	funz_id
BIO_PROC	Termini che descrivono eventi molecolari con un inizio e una fine definiti, pertinenti al funzionamento della cellula (es. 'Traporto')	funz_id, term	funz_id
MOL_FUN	Termini che descrivono attività elementari di un prodotto genico a livello molecolare (es. 'Attività catalitica')	funz_id, term	funz_id

RELAZIONI	DESCRIZIONE	ENTITÀ COINVOLTE	ATTRIBUTI

RESCLASS	Associa ogni tipo di resistenza alla sua classe di appartenenza	RES(1,1) CLASSE(1,n)	res, classe
CLMEC	Associa ogni classe di resistenza al proprio meccanismo di azione	CLASSE(1,1) MEC(1,n)	cl, mec
RESART	Associa ogni tipo di resistenza a uno o più articoli.	RES(1,n) ART(1,1)	res, art
ARTRIV	Associa ogni articolo ad ulteriori informazioni bibliografiche (volume, anno e rivista)	ART(1,1) RIV(1,n)	art, cod
REQ	Associa alcuni tipi di mutazioni di resistenza con altri tipi che devono essere contemporaneamente presenti affinché la mutazione abbia un effetto visibile.	RES(0,n) RES(0,n)	res, req
RESMUT	Associa ad ogni tipo di resistenza il relativo tipo di mutazione genetica.	RES(1,1) MUT(1,n)	res, tipo_m
RESANT	Associa ogni tipo di resistenza agli antibiotici di cui inattiva l'azione.	RES(1,n) ANT(1,n)	res, ant
ANTSUB	Associa ad ogni antibiotico la propria sottoclasse.	ANT(1,1) SUBCLASS(1,n)	ant, subcl
SUBATC	Associa ad ogni sottoclasse la propria classe superiore.	SUB_CLASS(1,1) ATC(1,n)	subcl, atc
ATCPATH	Associa ad ogni classe di antibiotici il *pathway* cellulari in cui si svolge la loro azione.	ANT(1,1,) PATHWAY(1,n)	atc, path
RESSEQ	Associa ad ogni tipo di resistenza le sequenza di DNA nelle quali è stata identificata	RES(1,n) SEQ(1,n)	res, seq

SEQBAT	Associa ad ogni sequenza la specie batterica a cui appartiene	SEQ(1,1) BAT(1,n)	seq, bat
BATFAM	Associa ad ogni specie batterica la propria famiglia di appartenenza nell'albero filogenetico.	BAT(1,1) FAM(1,n)	bat, fam
SEQPROT	Associa ogni sequenza di DNA la/e proteina/e da essa codificata/e	SEQ(1.n) PROT(1,1)	seq, prot
PROTFUNZ	Associa ad ogni proteina i termini che ne descrivono la funzione nella cellula	PROT(1,n) FUNZ(1,n)	prot, funz
ECPROT	Associa ad ogni enzima il proprio codice EC	ENZIMA(1,1) EC(1,n)	prot, ec
ECGR	Associa i codici EC dei singoli enzimi a quelli dei propri gruppi enzimatici di appartenenza.	EC(1,1) GRUPPO(1,n)	ec, group

4. RISOLUZIONE DELLE GENERALIZZAZIONI

Nello schema E-R logico sono presenti tre generalizzazioni (vedi Schema 5.1) del tipo **totale** (ogni istanza dell'entità padre deve far parte di una delle entità figlie) e **esclusivo** (ogni istanza dell'entità padre deve far parte di una sola delle entità figlie).

La generalizzazione ENZIMA, invece, è del tipo **parziale** (non tutte le istanze dell'entità padre fanno parte dell'entità figlia) ed **esclusivo**.

Si è scelto di risolvere le tre generalizzazioni di tipo **(t,e)** tramite l'**accorpamento delle figlie nel padre** (vedi Schema 5.2), ovvero eliminando le entità figlie ('COMPL' e 'NON_COMPL' (prima generalizzazione), 'CROMOSOMA' e 'PLASMIDE' (seconda generalizzazione), 'CELL_COMP', 'MOL_FUN' e 'BIO_PROC' (terza generalizzazione) e aggiungendo alle rispettive entità padre ('SEQUENZA' per le prime due generalizzazioni, e 'FUNZ' per la terza) un attributo di "tipo" che identifica l'appartenenza di ognuna delle occorrenze alle singole entità figlie. Nel caso dell'entità padre 'SEQUENZA' è stato aggiunto l'attributo 'tipo' identificante le sequenze di tipo cromosomico o plasmidico, e l'attributo 'compl', indicante se la sequenza è o meno completa. Nel

caso dell'entità padre 'FUNZ' è stato aggiunto un attributo 'tipo_f' indicante a quale dei tre tipi sopracitati appartiene la singola occorrenza.

Si è scelto di adottare questa soluzione poiché:

- Le entità figlie non presentavano attributi unici, ma solo gli attributi ereditati dall'entità padre. Questo permette un loro accorpamento nelle entità padre senza lo svantaggio di generare entità con un alto numero di attributi.
- Dal momento che le entità padre e figlie possiedono gli stessi attributi, con un accorpamento non si incorrerà nel rischio di dover inserir valori nulli a livello di attributi non condivisi da tutte le entità.
- Le generalizzazioni sono totali, quindi non si avrà mai la presenza di valori nulli a livello degli attributi aggiunti alle entità padre (situazione che si sarebbe verificata se fossero state presenti occorrenze dell'entità padre non classificabili in nessuno dei "tipi" delle occorrenze figlie).
- Si prevede che la maggior parte delle operazioni da effettuare sul database riguarderanno le entità padre SEQ e FUNZ e non le proprie singole generalizzazioni separatamente, quindi è più conveniente raggruppare le occorrenze in una sola entità che separarle in più entità.

Per quanto riguarda la generalizzazione del tipo **(p,e)** dell'entità PROTEINA, si è scelto di risolverla tramite la **sostituzione della generalizzazione con una relazione** tra l'entità padre PROT e l'entità EC. La relazione avrà cardinalità (0,1) per quanto riguarda l'entità PROT poiché la generalizzazione è di tipo parziale, quindi non tutte le occorrenze di proteina saranno enzimi e avranno una corrispondenza con un codice enzimatico dell'entità EC.

5. SCHEMI E-R

5.1 Schema E-R logico

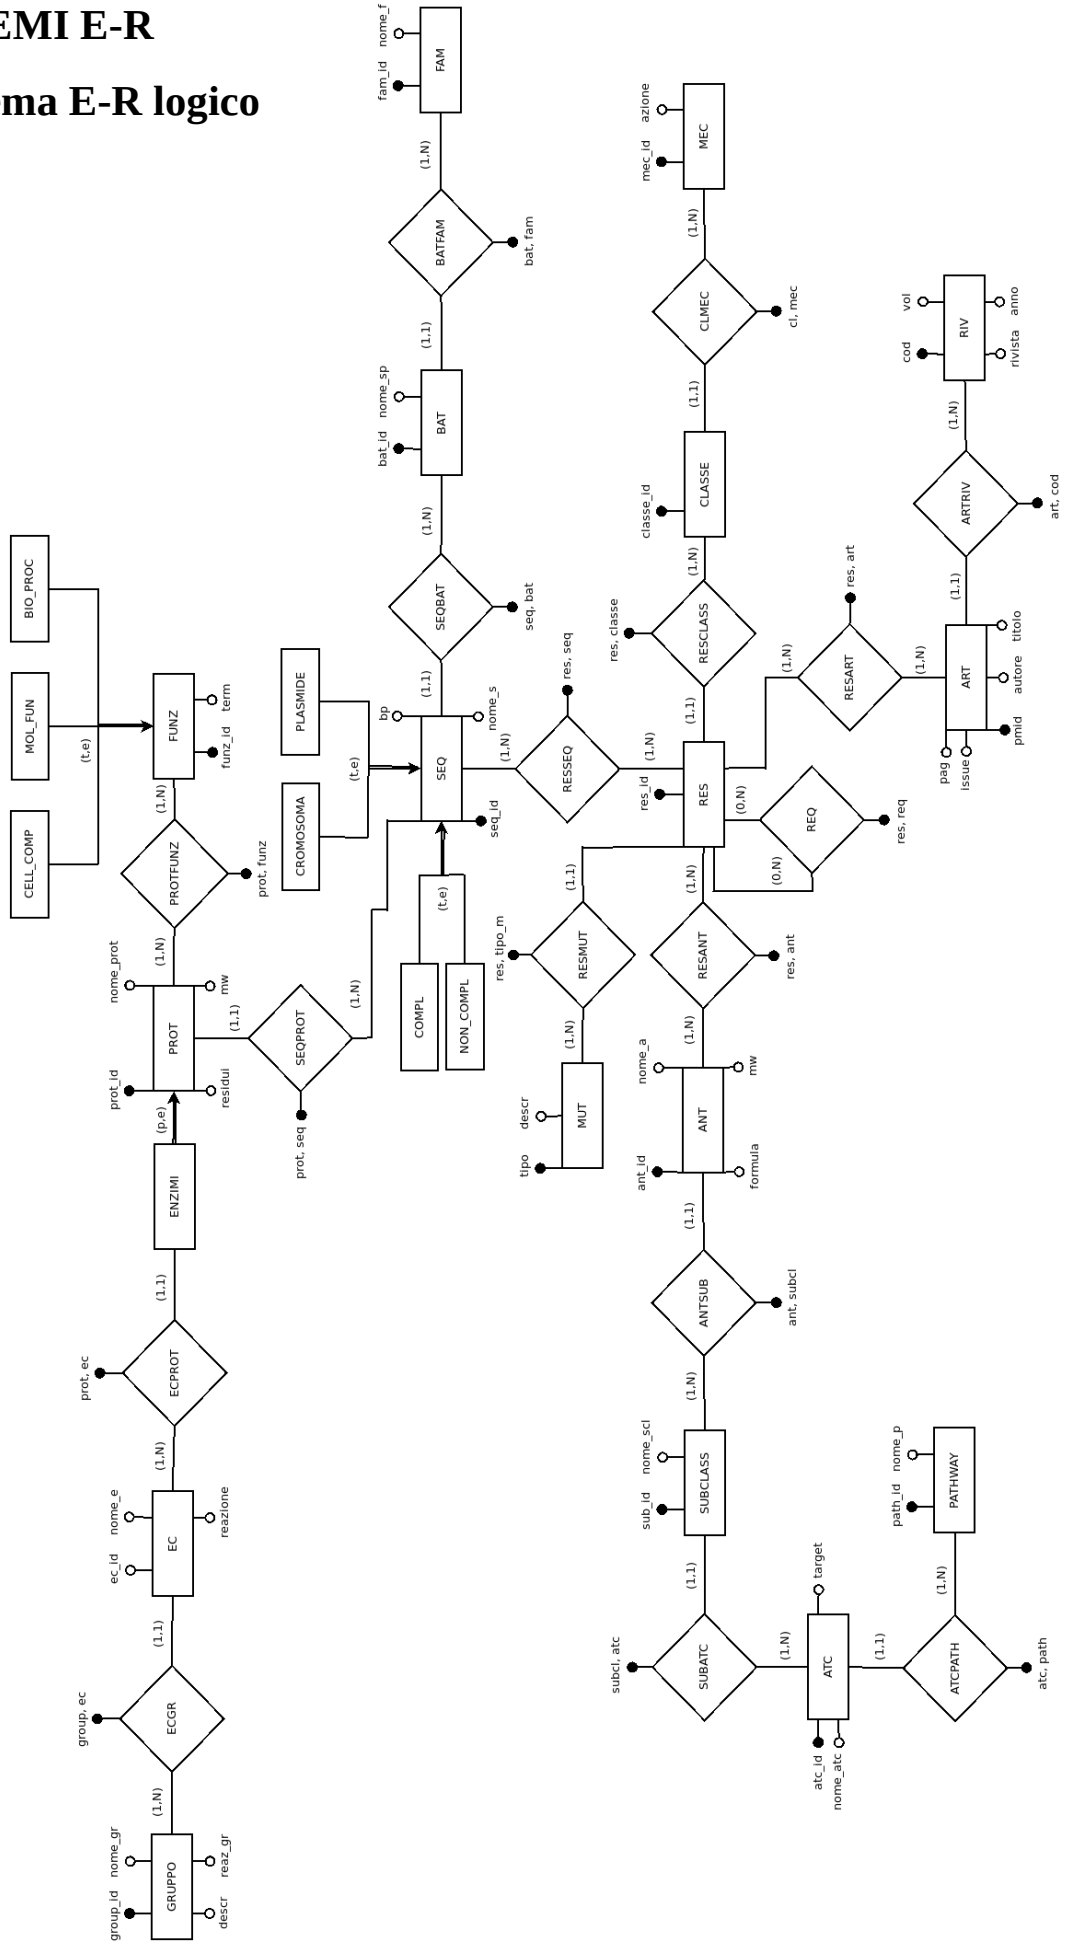

5.2 Schema E-R con risoluzione delle generalizzazioni

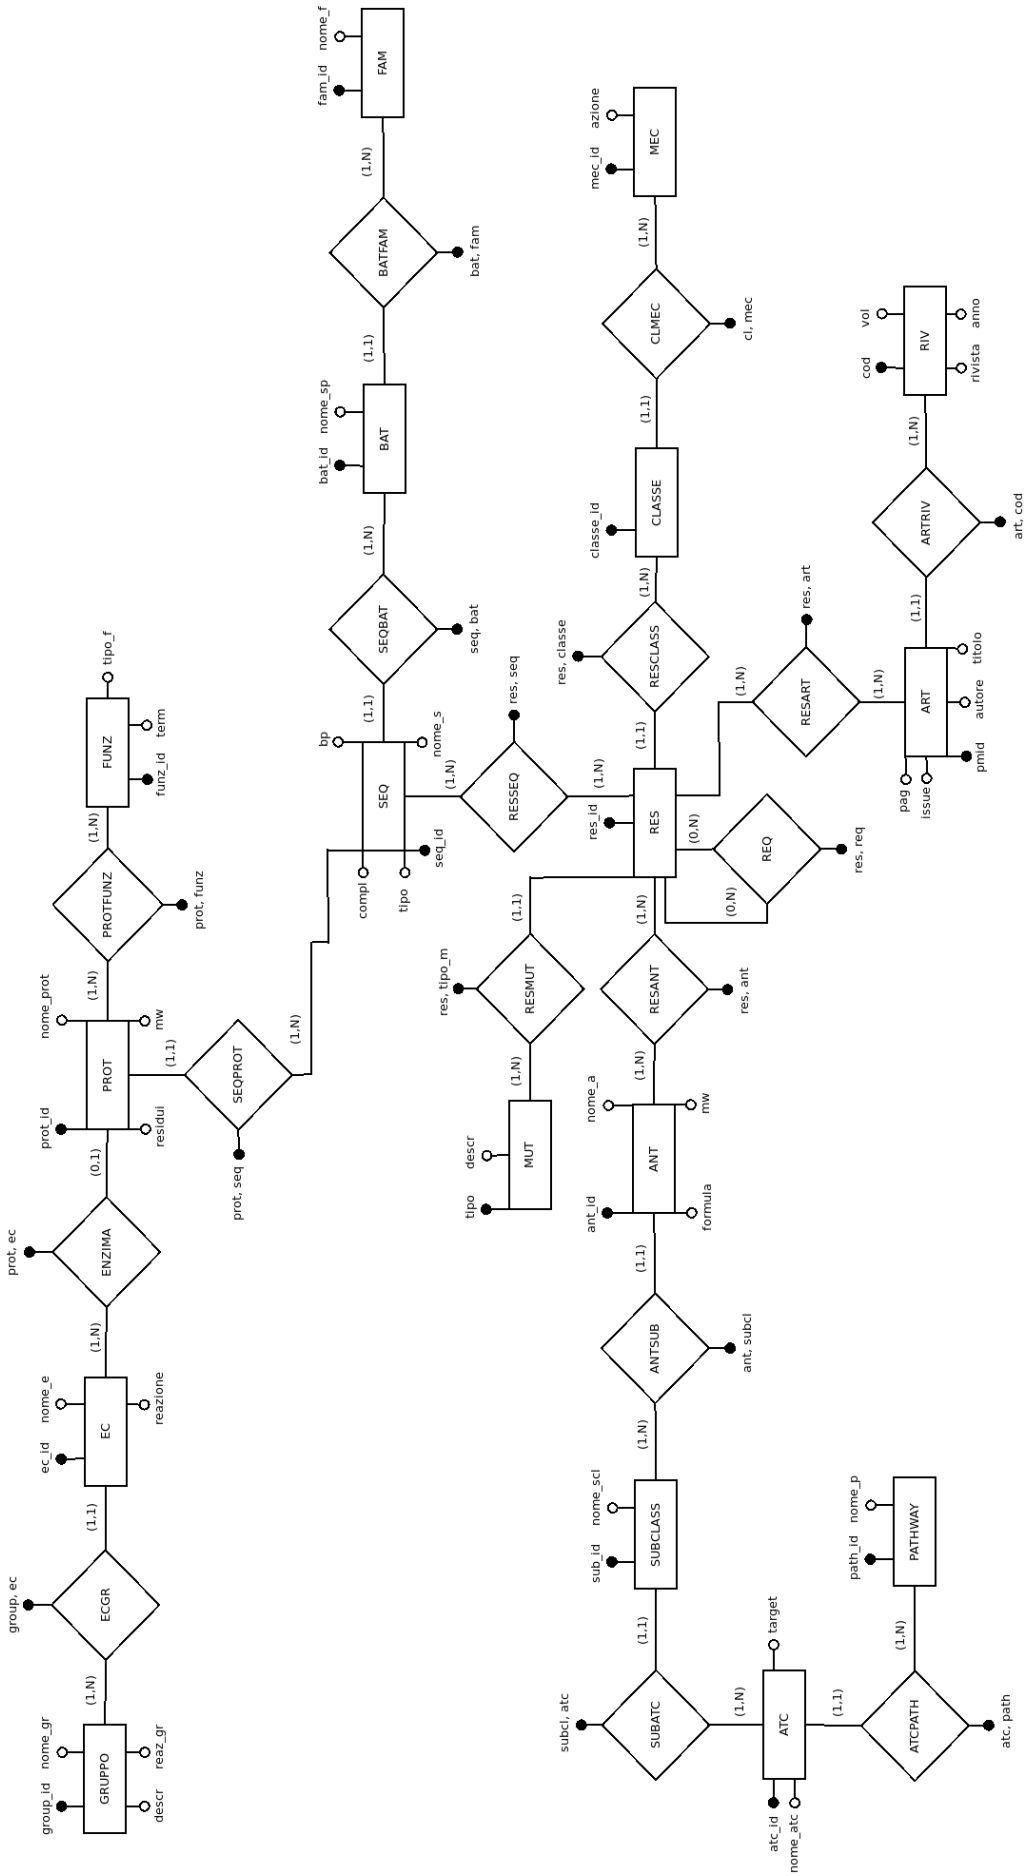

5.3 Schema E-R fisico

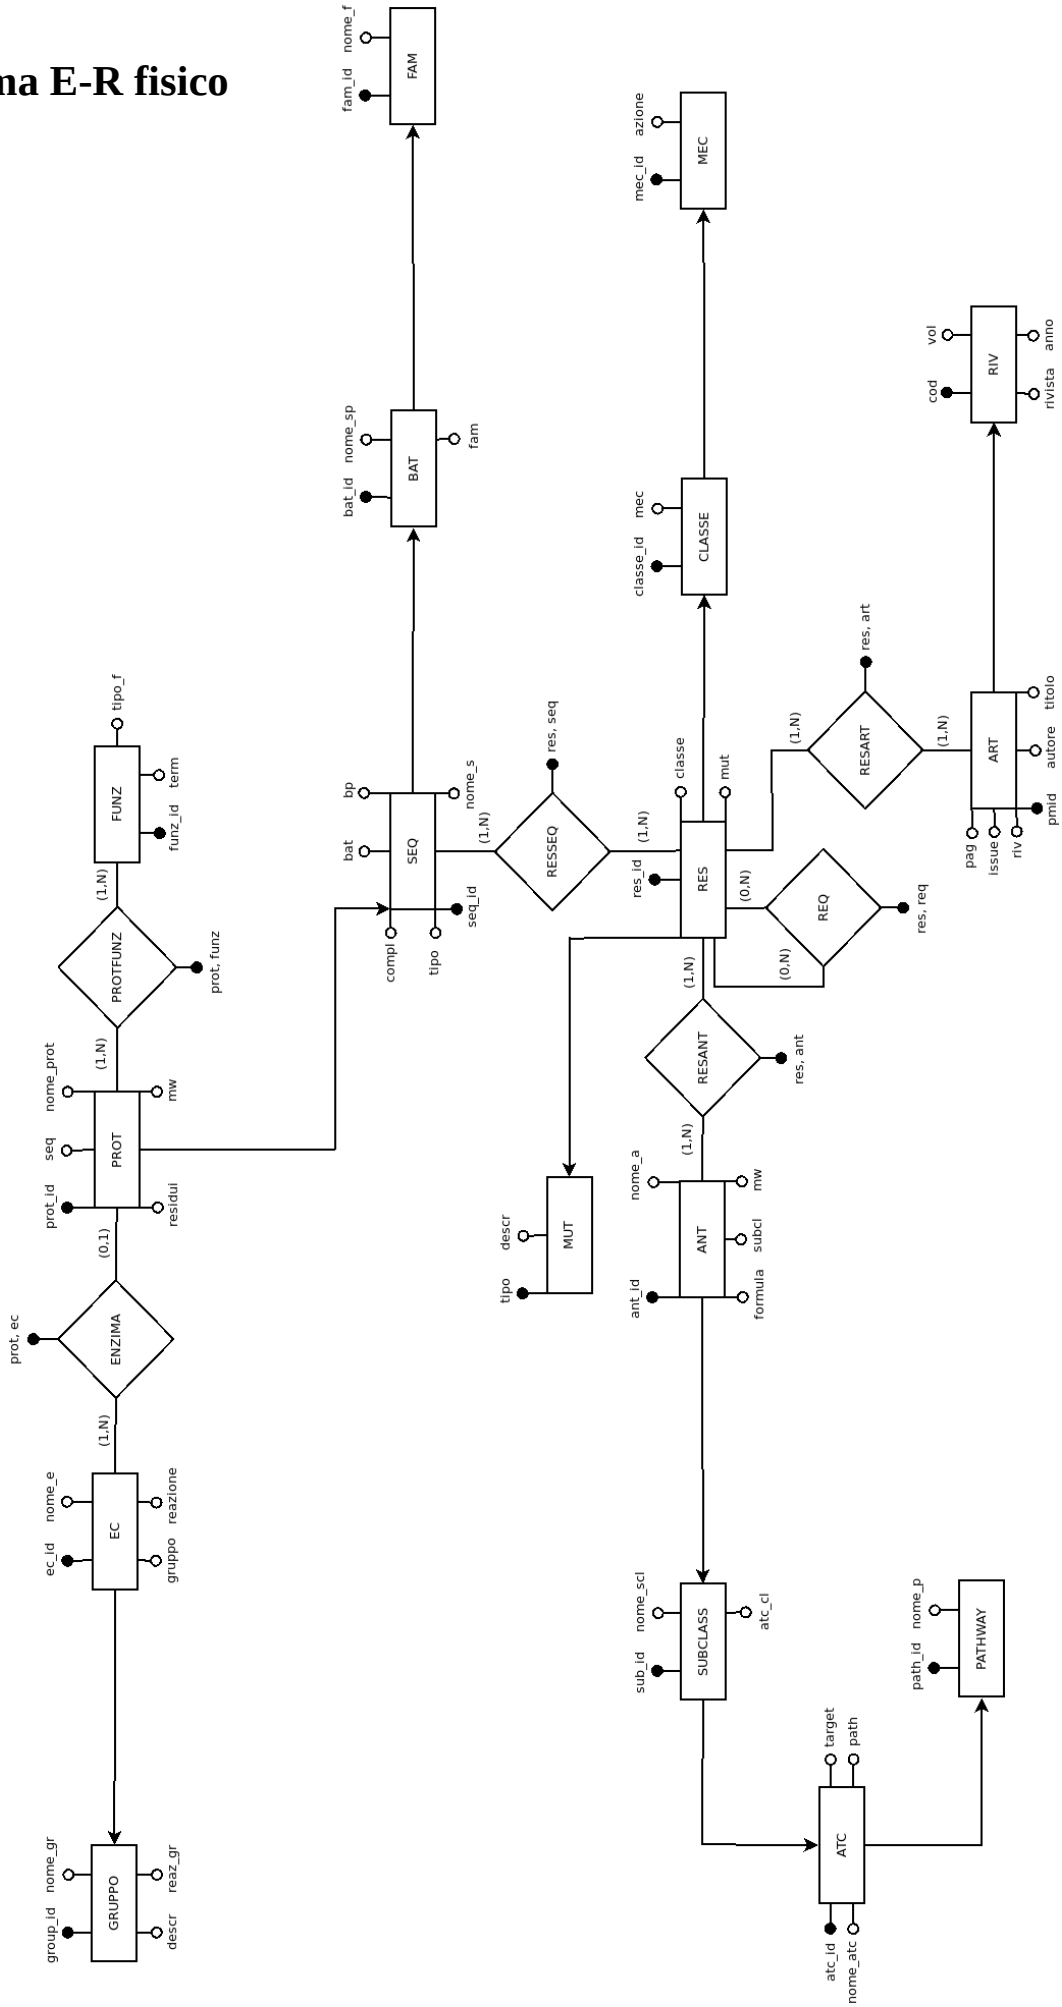

5.3.1. Commenti sullo schema E-R

La relazione tra le entità ANT, RES e SEQ poteva essere rappresentata anche tramite una unica relazione ternaria, poiché tutte le tre entità sono in relazione tra loro con una cardinalità (1,n). Si è scelto però di rappresentarle con due relazioni separate, in parte per mantenere la separazione tra i due concetti (mutazioni di resistenza e antibiotici inattivati, mutazioni di resistenza e sequenze sulle quali sono state ritrovate) e in parte poichè il numero di sequenze associate a più di una resistenza è molto minore rispetto al totale delle sequenze contenute nel database (vedi Query 22), e questo in una relazione ternaria (1,N)-(1,N)-(1,N) avrebbe causato la presenza di molti valori ridondanti a livello dell'attributo 'sequenza'.

6. TRADUZIONE DELLO SCHEMA E-R FISICO NEL MODELLO RELAZIONALE

Entità

MUT(tipo, descr)
FAM(fam_id, nome_f)
MEC(mec_id, azione)
GRUPPO(group_id, nome_gr, descr, reaz_gr)
FUNZ(funz_id, term, tipo_f)
PATHWAY(path_id, nome_p)
RIV (cod, vol, anno, rivista)
ART(pmid, autore, riv, issue, pag, titolo)
CLASSE(class_id, mec)
ATC(atc_id, nome_atc, target, path)
SUBCLASS(sub_id, nome_scl, atc_cl)
EC(ec_id, nome_e, reazione, gruppo)
BAT(bat_id, nome_sp, fam)
RES(res_id, classe, mut)
SEQ(seq_id, nome_s, bp, tipo, compl, bat)
PROT(prot_id, nome_pr, residui, mw, seq)
ANT(ant_id, nome_a, formula, mw, subcl)

Relazioni

REQ(res, req)
RESANT(res, ant)
RESART(res,art)
RESSEQ(res,seq)
PROTFUNZ(prot, funz)
ENZIMA(prot,ec)

7. CREAZIONE DEL DATABASE

```
create database ResistanceBase;

use ResistanceBase;

create table mut (
      tipo varchar(50) not null primary key,
      descr varchar(300) not null
      )Engine=InnoDB;

create table fam (
      fam_id int not null primary key,
      nome_f varchar(50) not null
     )Engine=InnoDB;

create table mec (
      mec_id char(4) not null primary key,
      azione varchar(100) not null
     )Engine=InnoDB;

create table gruppo (
      group_id char(3) not null primary key,
      nome_gr varchar(20) not null,
      descr varchar(100) not null,
      reaz_gr varchar(50) not null
     )Engine=InnoDB;

create table funz (
      funz_id char(10) not null primary key,
      term varchar(50) not null,
      tipo_f enum('BP','CC', 'MF') not null
     )Engine=InnoDB;

create table pathway (
      path_id char(4) not null primary key,
      nome_p varchar(100) not null
     )Engine=InnoDB;

create table riv (
      cod int not null primary key auto_increment,
      issue int not null,
      vol int not null,
      anno year not null,
      rivista varchar(30) not null
      )Engine=InnoDB;

create table art (
      pmid int not null primary key,
      autore varchar(30) not null,
      riv int not null,
      issue int not null,
```

```
      pag varchar(10) not null,
      titolo varchar(200) not null,
      foreign key (riv) references riv (cod) on update cascade on
delete no action
     )Engine=InnoDB;

create table classe (
      class_id varchar(15) not null primary key,
      mec char(4) not null,
      foreign key (mec) references mec (mec_id) on update cascade on
delete no action
      )Engine=InnoDB;

create table atc (
      atc_id char(4) not null primary key,
      nome_atc varchar(50) not null,
      target varchar(50) not null,
      path char(4) not null,
      foreign key (path) references pathway (path_id) on update cascade
on delete no action
      )Engine=InnoDB;

create table subclass (
      sub_id char(5) not null primary key,
      nome_scl varchar(100) not null,
      atc_cl char(4) not null,
      foreign key (atc_cl) references atc (atc_id) on update cascade on
delete no action
      )Engine=InnoDB;

create table ec (
      ec_id varchar(15) not null primary key,
      nome_e varchar(100) not null,
      reazione varchar(150) not null,
      gruppo char(3) not null,
      foreign key (gruppo) references gruppo (group_id) on update cascade
on delete no action
      )Engine=InnoDB;

create table bat (
      bat_id int not null primary key,
      nome_sp varchar(100) not null,
      fam int not null,
      foreign key (fam) references fam (fam_id) on update cascade on
delete no action
       )Engine=InnoDB;

create table res (
      res_id varchar(10) not null primary key,
      classe varchar(15) not null,
      mut varchar(50) not null,
      foreign key (classe) references classe (class_id) on update cascade
on delete no action,
```

```
     foreign key (mut) references mut (tipo) on update cascade on delete
no action
    )Engine=InnoDB;

create table seq (
     seq_id varchar(20) not null primary key,
     nome_s varchar(10) not null,
     bp int not null,
     tipo enum('Cromosoma','Plasmide') not null,
     compl enum('Y','N') not null,
     bat int not null,
     foreign key (bat) references bat (bat_id) on update cascade on
delete no action
     )Engine=InnoDB;

create table prot (
     prot_id varchar(15) not null primary key,
     nome_pr varchar(10) not null,
     residui int not null,
     mw int not null,
     seq varchar(20) not null,
     foreign key (seq) references seq (seq_id) on update cascade on
delete no action
     )Engine=InnoDB;

create table ant (
     ant_id char(7) not null primary key,
     nome_a varchar(30) not null,
     formula varchar(20) not null,
     mw int not null,
     subcl char(5) not null,
    foreign key (subcl) references subclass (sub_id) on update cascade
on delete no action
    )Engine=InnoDB;

create table resant (
     res varchar(10) not null,
     ant char(7) not null,
     foreign key (res) references res (res_id) on update cascade on
delete no action,
    foreign key (ant) references ant (ant_id) on update cascade on
delete no action,
     primary key (res, ant)
    )Engine=InnoDB;

create table resart (
     res varchar(10) not null,
     art int not null,
     foreign key (res) references res (res_id) on update cascade on
delete no action,
    foreign key (art) references art (pmid) on update cascade on delete
no action,
     primary key (res, art)
```

```
     )Engine=InnoDB;

create table resseq (
      res varchar(10) not null,
      seq varchar(20) not null,
      foreign key (res) references res (res_id) on update cascade on
delete no action,
     foreign key (seq) references seq (seq_id) on update cascade on
delete no action,
      primary key (res, seq)
     )Engine=InnoDB;

create table req (
      res varchar(10) not null,
      req varchar(10) not null,
      foreign key (res) references res (res_id) on update cascade on
delete no action,
     foreign key (req) references res (res_id) on update cascade on
delete no action,
      primary key (res, req)
     )Engine=InnoDB;

create table protfunz (
      prot varchar(15) not null,
      funz char(10) not null,
      foreign key (prot) references prot (prot_id) on update cascade on
delete no action,
     foreign key (funz) references funz (funz_id) on update cascade on
delete no action,
      primary key (prot, funz)
      )Engine=InnoDB;

create table enzima (
      prot varchar(15) not null,
      ec varchar(15) not null,
      foreign key (prot) references prot (prot_id) on update cascade on
delete no action,
      foreign key (ec) references ec (ec_id) on update cascade on delete
no action,
      primary key (prot, ec)
      )Engine=InnoDB;
```

8. INSERIMENTO DEI DATI

L'inserimento dei dati in un database MySQL può avvenire in due modi:

- Inserimento manuale di singole o multiple entry tramite comando di '*insert*'
- Inserimento automatico da file, formattati in modo tale che le singole entry possano essere riconosciute da MySQL ed inserite correttamente nelle rispettive colonne attributo. Il comando da utilizzare è '*load data local infile*', per file memorizzati localmente.

In questo database i dati sono stati inseriti tramite inserimento da file. Per brevità, non viene riportato il contenuto dei file inseriti ma solo la struttura di base del comando utilizzato:

```
LOAD DATA LOCAL INFILE <'nome_file.dat'> INTO TABLE <nome_tabella>
FIELDS TERMINATED BY '\t'
ENCLOSED BY "'"
LINES TERMINATED BY '\n'
(<attr1>, <attr2>,…,<attrN>);
```

Si riporta a titolo esemplificativo anche un inserimento tramite comando di '*insert*', per i dati relativi all'entità MEC:

```
INSERT INTO mec (mec_id, azione) VALUES ('M01', 'Distruzione
enzimatica dell'antibiotico');
INSERT INTO mec (mec_id, azione) VALUES ('M02', 'Modificazione del
target dell'antibiotico');
INSERT INTO mec (mec_id, azione) VALUES ('M03', 'Modificazione
chimica dell'antibiotico');
INSERT INTO mec (mec_id, azione) VALUES ('M04', 'Efflusso
dell'antibiotico');
INSERT INTO mec (mec_id, azione) VALUES ('M05', 'Diminuzioe della
penetrazione cellulare dell'antibiotico');
INSERT INTO mec (mec_id, azione) VALUES ('M06', 'Sostituzione del
target dell'antibiotico');
INSERT INTO mec (mec_id, azione) VALUES ('M07', 'Protezione del
target dell'antibiotico');
```

9. QUERY

1. Selezionare le resistenze che interferiscono con almeno 3 antibiotici, mostrando il numero di antibiotici con cui interferiscono

```
select res, count(ant) antibiotici from resant group by res having
count(ant)>=3;
```

```
+------+-------------+
| res  | antibiotici |
+------+-------------+
| norm |           4 |
+------+-------------+
1 row in set (0,00 sec)
```

2. Selezionare gli articoli pubblicati dal 2005 al 2010, mostrando autore, anno, rivista e il tipo di resistenza a cui si riferiscono, mostrandoli in ordine cronologico.

```
select autore, anno, rivista, res from riv, art, resart where
resart.art=art.pmid and riv.cod=art.riv and anno between 2005 and
2010 order by anno;
```

```
+--------------+------+----------------------------+--------+
| autore       | anno | rivista                    | res    |
+--------------+------+----------------------------+--------+
| Li, XZ       | 2005 | Antimicrob Agents Chemother | mexa   |
| Li, XZ       | 2005 | Antimicrob Agents Chemother | mexb   |
| Li, XZ       | 2005 | Antimicrob Agents Chemother | oprm   |
| LeBlanc, DJ  | 2006 | Nucleic Acids Res           | teto   |
| Martin, P    | 2006 | Gene                        | tetm   |
| Cameron, FH  | 2006 | Gene                        | ant2ia |
| Poole, K     | 2006 | Mol Microbiol               | mexd   |
| Musso, R     | 2007 | Proc Natl Acad Sci U S A    | mdte   |
| Musso, R     | 2007 | Proc Natl Acad Sci U S A    | mdtf   |
| Köhler, T    | 2007 | Mol Microbiol               | mexe   |
| Köhler, T    | 2007 | Mol Microbiol               | mexf   |
| Köhler, T    | 2007 | Mol Microbiol               | oprn   |
| Scott, KP    | 2007 | Appl Environ Microbiol      | tetw   |
| Kunst, F     | 2007 | Nature                      | lmrb   |
| Hiramatsu, K | 2007 | Lancet                      | norm   |
| Scholz, P    | 2008 | J Bacteriol                 | aph3ic |
+--------------+------+----------------------------+--------+
16 rows in set (0,00 sec)
```

3a. Selezionare l'autore e l'anno dell'articolo che è stato pubblicato più anteriormente, con la/le resistenza/e a cui fa riferimento **(<u>Select nidificata</u>)**

```
select autore, anno, res resistenza from riv, art, resart where
resart.art=art.pmid and riv.cod=art.riv and anno=(select min(anno)
from riv);
```

```
+----------+------+------------+
| autore   | anno | resistenza |
+----------+------+------------+
| Tovar, K | 1988 | tete       |
+----------+------+------------+
1 row in set (0,04 sec)
```

3b (**Senza select nidificata**)

```
select autore, anno, res resistenza from riv, art, resart where
resart.art=art.pmid and riv.cod=art.riv order by anno LIMIT 1;
```

```
+----------+------+------------+
| autore   | anno | resistenza |
+----------+------+------------+
| Tovar, K | 1988 | tete       |
+----------+------+------------+
1 row in set (0,00 sec)
```

4. Selezionare i titoli degli articoli il cui titolo contiene la parola “antibiotic”.

```
select titolo from art where titolo like "%antibiotic%";
```

```
+-----------------------------------------------------------------------------------------
-----------------------------+
| titolo
|
+-----------------------------------------------------------------------------------------
-----------------------------+
| Multiple antibiotic resistance in Pseudomonas aeruginosa: evidence for involvement of
an efflux operon.              |
| Role of mexA-mexB-oprM in antibiotic efflux in Pseudomonas aeruginosa.
|
| Tetracycline antibiotics: mode of action, applications, molecular biology, and
epidemiology of bacterial resistance. |
+-----------------------------------------------------------------------------------------
-----------------------------+
3 rows in set (0,00 sec)
```

5. Mostrare quanti sono, per ogni classe di resistenza, i tipi di resistenza associati alla tetraciclina, raggruppandoli per il meccanismo di resistenza di ogni classe

```
select count(res.res_id) resistenze, res.classe, azione from
resant, ant, res, mec, classe  where resant.res=res.res_id and
resant.ant=ant.ant_id and res.classe=classe.class_id and
classe.mec=mec.mec_id and ant.nome_a="Tetraciclina" group by
azione, res.classe;
```

```
+------------+------------+----------------------------------------+
| resistenze | classe     | azione                                 |
+------------+------------+----------------------------------------+
|          3 | mex        | Efflusso dell'antibiotico              |
|          9 | tet_efflux | Efflusso dell'antibiotico              |
|          4 | tet_rpp    | Protezione del target dell'antibiotico |
|          1 | tet_mod    | Distruzione enzimatica dell'antibiotico |
+------------+------------+----------------------------------------+
4 rows in set (0,00 sec)
```

6. Selezionare gli antibiotici che iniziano per ‘S’ e le relative proteine nelle quali sono state trovate mutazioni correlate alla loro inibizione

```
select ant.nome_a antibiotico, prot.prot_id from ant, resant, res,
resseq, seq, prot where resant.ant=ant.ant_id and
resant.res=res.res_id and res.res_id=resseq.res and
```

```
resseq.seq=sqe.seq_id and seq.seq_id=prot.seq and ant.nome_a like
'S%';
+---------------+-------------+
| antibiotico   | prot_id     |
+---------------+-------------+
| Streptomicina | BAA06249    |
| Streptomicina | AAP74962    |
| Streptomicina | AAT38947    |
| Streptomicina | ABB99436    |
| Streptomicina | ABO46016    |
| Streptomicina | AAC98719    |
| Streptomicina | BAC94494    |
| Streptomicina | ZP_01993435 |
+---------------+-------------+
8 rows in set (0,00 sec)
```

7. Selezionare tutti gli organismi batterici della famiglia delle *Enterobacteriaceae* e gli antibiotici per i quali sono resistenti

```
select distinct nome_sp batterio, ant.nome_a antibiotico from bat,
fam, ant, resant, res, resseq, seq where ant.ant_id=resant.ant and
resant.res=res.res_id and res.res_id=resseq.res and
resseq.seq=seq.seq_id and seq.bat=bat.bat_id and
bat.fam=fam.fam_id and fam.nome_f="Enterobacteriaceae" ;

+------------------------+----------------+
| batterio               | antibiotico    |
+------------------------+----------------+
| Enterobacter cloacae   | Gentamicina    |
| Enterobacter cloacae   | Kanamicina     |
| Enterobacter cloacae   | Streptomicina  |
| Enterobacter cloacae   | Carbenicillina |
| Escherichia coli       | Eritromicina   |
| Escherichia coli       | Gentamicina    |
| Escherichia coli       | Kanamicina     |
| Klebsiella pneumoniae  | Eritromicina   |
| Klebsiella pneumoniae  | Streptomicina  |
| Salmonella typhimurium | Streptomicina  |
| Salmonella typhimurium | Cloramfenicolo |
| Salmonella typhimurium | Tetraciclina   |
| Shigella sonnei        | Tetraciclina   |
| Salmonella enterica    | Tetraciclina   |
| Salmonella enterica    | Carbenicillina |
| Salmonella enterica    | Gentamicina    |
+------------------------+----------------+
16 rows in set (0,01 sec)
```

8. Selezionare le proteine mutate coinvolte nella resistenza per la Gentamicina e mostrare informazioni sulla loro funzione nella cellula

```
select prot.nome_pr, funz.term funzione from prot, protfunz, funz,
seq, resseq, res, resant, ant where prot.prot_id=protfunz.prot and
protfunz.funz=funz.funz_id and prot.seq=seq.seq_id and
seq.seq_id=resseq.seq and resseq.res=res.res_id and
res.res_id=resant.res and resant.ant=ant.ant_id and
ant.nome_a="Gentamicina";
```

nome_pr	funzione
prot1	Trasporto di farmaci
prot1	Attività transferasica
prot1	Aminoglicoside N-acetiltransferasi
prot4	Trasporto di farmaci
prot4	Attività transferasica
prot4	Aminoglicoside N-acetiltransferasi
prot3	Trasporto di farmaci
prot3	Attività transferasica
prot3	Aminoglicoside N-acetiltransferasi
prot5	Trasporto di farmaci
prot5	Attività transferasica
prot5	Aminoglicoside N-acetiltransferasi
prot14	Attività transferasica
prot14	Aminoglicoside nucleotidiltransferasi
prot13	Attività transferasica
prot13	Aminoglicoside nucleotidiltransferasi
prot15	Attività transferasica
prot15	Aminoglicoside nucleotidiltransferasi
prot21	Attivià chinasica
prot21	Fosforilazione
prot21	Attività transferasica
prot21	Attività fosfotransferasica su gruppi alcolici
prot21	Aminoglicoside fosfotransferasi
prot25	Attivià chinasica
prot25	Fosforilazione
prot25	Attività transferasica
prot25	Attività fosfotransferasica su gruppi alcolici
prot25	Aminoglicoside fosfotransferasi

28 rows in set (0,01 sec)

9. Mostrare in ordine crescente quante proteine sono accomunate dalla stessa funzione molecolare o processo biologico e mostrare i relativi termini e codici *Gene Ontology*

```
select count(*) proteine, protfunz.funz GO_ID, funz.term funzione
from protfunz, funz where protfunz.funz=funz.funz_id and tipo_f in
('BP','MF') group by protfunz.funz;
```

proteine	GO_ID	funzione
1	GO:0022402	Ciclo cellulare
1	GO:0045023	Transizione G0-G1
1	GO:0003824	Attività ossido-reduttasica
1	GO:0016491	Processo di ossido-riduzione
2	GO:0015399	Trasporto attivo primario transmembrana
2	GO:0016787	Attività idrolasica
3	GO:0016301	Attivià chinasica
3	GO:0016310	Fosforilazione
3	GO:0016773	Attività fosfotransferasica su gruppi alcolici
4	GO:0006412	Traduzione
4	GO:0090079	Regolazione della traduzione
4	GO:0008135	Legame dell'RNA
4	GO:0010468	Regolazione dell'espressione genica
9	GO:0015665	Trasporto transmembrana di composti alcolici
11	GO:0006811	Trasporto di ioni
16	GO:0016740	Attività transferasica
42	GO:0055085	Trasporto transmembrana
47	GO:0015893	Trasporto di farmaci

```
+----------+-----------+-------------------------------------------------+
18 rows in set (0,00 sec)
```

10a. Selezionare le proteine che hanno associati gli stessi *Gene Ontology* ID di “prot15“, le resistenze ad esse associate (tipo e classe) e il relativo meccanismo di azione, ordinando per classe di resistenza in maniera crescente. **(Select nidificata)**

```
select distinct prot.prot_id proteina, res.res_id, res.classe,
azione from prot, protfunz, seq, resseq, res, classe, mec where
funz in (select funz from protfunz, prot where
prot.nome_pr="prot15" and prot.prot_id=protfunz.prot) and
prot.prot_id=protfunz.prot and prot.seq=seq.seq_id and
seq.seq_id=resseq.seq and resseq.res=res_id and
res.classe=classe.class_id and classe.mec=mec.mec_id and
prot.nome_pr!="prot15" order by res.classe;
```

```
+-----------+---------+--------+---------------------------------------+
| proteina  | res_id  | classe | azione                                |
+-----------+---------+--------+---------------------------------------+
| AAA16194  | aac3vi  | aac    | Modificazione chimica dell'antibiotico |
| AAA25680  | aac6iib | aac    | Modificazione chimica dell'antibiotico |
| AAU09447  | aac3iia | aac    | Modificazione chimica dell'antibiotico |
| ABO41023  | aac3vi  | aac    | Modificazione chimica dell'antibiotico |
| AAP74962  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| AAS79146  | ant2ia  | ant    | Modificazione chimica dell'antibiotico |
| AAT38947  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| ABB99436  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| ABO46016  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| BAA06249  | aadd    | ant    | Modificazione chimica dell'antibiotico |
| CAI40606  | ant2ia  | ant    | Modificazione chimica dell'antibiotico |
| AAC98719  | aph6ia  | aph    | Modificazione chimica dell'antibiotico |
| CAA30578  | aph3via | aph    | Modificazione chimica dell'antibiotico |
| CAA88266  | aph3ic  | aph    | Modificazione chimica dell'antibiotico |
| YP_758627 | lnua    | lnu    | Modificazione chimica dell'antibiotico |
+-----------+---------+--------+---------------------------------------+
15 rows in set (0,01 sec)
```

10b. **(Alias)**

```
select distinct x.prot_id proteina, res.res_id, res.classe, azione
from prot x, prot y, protfunz a, protfunz b, seq, resseq, res,
classe, mec where x.prot_id=a.prot and y.prot_id=b.prot and
a.funz=b.funz and x.seq=seq.seq_id and seq.seq_id=resseq.seq and
resseq.res=res_id and res.classe=classe.class_id and
classe.mec=mec.mec_id and y.nome_pr="prot15" and
x.nome_pr!="prot15" order by res.classe;
```

```
+-----------+---------+--------+---------------------------------------+
| proteina  | res_id  | classe | azione                                |
+-----------+---------+--------+---------------------------------------+
| AAA16194  | aac3vi  | aac    | Modificazione chimica dell'antibiotico |
| AAA25680  | aac6iib | aac    | Modificazione chimica dell'antibiotico |
| AAU09447  | aac3iia | aac    | Modificazione chimica dell'antibiotico |
| ABO41023  | aac3vi  | aac    | Modificazione chimica dell'antibiotico |
| AAP74962  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| AAS79146  | ant2ia  | ant    | Modificazione chimica dell'antibiotico |
| AAT38947  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
```

```
| ABB99436  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| ABO46016  | ant3ia  | ant    | Modificazione chimica dell'antibiotico |
| BAA06249  | aadd    | ant    | Modificazione chimica dell'antibiotico |
| CAI40606  | ant2ia  | ant    | Modificazione chimica dell'antibiotico |
| AAC98719  | aph6ia  | aph    | Modificazione chimica dell'antibiotico |
| CAA30578  | aph3via | aph    | Modificazione chimica dell'antibiotico |
| CAA88266  | aph3ic  | aph    | Modificazione chimica dell'antibiotico |
| YP_758627 | lnua    | lnu    | Modificazione chimica dell'antibiotico |
+-----------+---------+--------+----------------------------------------+
15 rows in set (0,01 sec)
```

11. Selezionare gli ID delle proteine coinvolte nella regolazione dell'espressione genica

```
select prot.prot_id from prot, protfunz, funz where
prot.prot_id=protfunz.prot and funz.funz_id=protfunz.funz and
term="Regolazione dell'espressione genica";
```

```
+----------+
| prot_id  |
+----------+
| AAF01499 |
| ABO25866 |
| ABO87315 |
| CAD20560 |
+----------+
4 rows in set (0,00 sec)
```

12. Contare, tra le proteine, quanti sono gli enzimi, mostrando anche il totale e raggruppando per gruppo enzimatico di appartenenza

```
select coalesce(nome_gr, "Totale") as "gruppo enzimatico",
coalesce(count(*)) as enzimi from enzima, ec, gruppo where
enzima.ec=ec.ec_id and gruppo.group_id=ec.gruppo group by nome_gr
with rollup;
+------------------+--------+
| gruppo enzimatico | enzimi |
+------------------+--------+
| Idrolasi         |      2 |
| Transferasi      |     16 |
| Translocasi      |      1 |
| Totale           |     19 |
+------------------+--------+
4 rows in set (0,00 sec)
```

13. Selezionare le specie batteriche resistenti a più di 5 antibiotici diversi, e mostrare quanti.

```
select bat.nome_sp specie, count(distinct resant.ant) antibiotici
from bat, seq, resseq, res, resant where seq.bat=bat.bat_id and
seq.seq_id=resseq.seq and resseq.res=res.res_id and
res.res_id=resant.res group by bat.nome_sp having antibiotici>=5;
```

```
+------------------------+-------------+
| specie                 | antibiotici |
+------------------------+-------------+
| Pseudomonas aeruginosa |           8 |
+------------------------+-------------+
```

```
1 row in set (0,01 sec)
```

14. Selezionare le proteine che hanno un numero di residui compreso tra 100 e 200 e mostrare l'id delle proteine, il numero di residui, la sequenza genica da cui derivano e l'organismo a cui appartengono

```
select prot.prot_id, prot.residui, prot.seq, bat.nome_sp from
prot, seq, bat where seq.seq_id=prot.seq and seq.bat=bat.bat_id
and residui between 100 and 200;
```

```
+----------+---------+----------+-----------------------+
| prot_id  | residui | seq      | nome_sp               |
+----------+---------+----------+-----------------------+
| ABI90248 |     134 | CP000441 | Burkholderia ambifaria |
| EDK55609 |     148 | DS264095 | Burkholderia mallei    |
+----------+---------+----------+-----------------------+
2 rows in set (0,00 sec)
```

15. Mostrare per ogni enzima il relativo ID, il gruppo enzimatico, la reazione specifica catalizzata e l'antibiotico nella cui inibizione è coinvolto

```
select distinct prot.prot_id enzima, gruppo.nome_gr gruppo,
ec.reazione, ant.nome_a antibiotico from enzima, ec, gruppo, ant,
res, resant, resseq, seq, prot where enzima.ec=ec.ec_id and
ec.gruppo=gruppo.group_id and enzima.prot=prot_id and
prot.seq=seq.seq_id and seq.seq_id=resseq.seq and
resseq.res=res.res_id and res.res_id=resant.res and
resant.ant=ant.ant_id;
```

```
+-----------+-------------+-------------------------------------------------------------
---------------------------------------------+----------------+
| enzima    | gruppo      | reazione
| antibiotico    |
+-----------+-------------+-------------------------------------------------------------
---------------------------------------------+----------------+
| AAA16194  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Carbenicillina |
| AAA16194  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Gentamicina    |
| AAA25680  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Gentamicina    |
| AAU09447  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Gentamicina    |
| AAU09447  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Kanamicina     |
| ABO41023  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Carbenicillina |
| ABO41023  | Transferasi | Acetyl-CoA + a 2-deossistreptamina <=> CoA + N(3)-acetil-2-
deossostreptamina                                | Gentamicina    |
| AAC98719  | Transferasi | GTP + gentamicina <=> GDP + gentamicina 2'-fosfato
| Streptomicina  |
| CAA30578  | Transferasi | GTP + gentamicina <=> GDP + gentamicina 2'-fosfato
| Gentamicina    |
| CAA30578  | Transferasi | GTP + gentamicina <=> GDP + gentamicina 2'-fosfato
| Kanamicina     |
| CAA88266  | Transferasi | GTP + gentamicina <=> GDP + gentamicina 2'-fosfato
| Gentamicina    |
```

```
| CAA88266  | Transferasi | GTP + gentamicina <=> GDP + gentamicina 2'-fosfato
| Kanamicina     |
| AAA25683  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Gentamicina    |
| AAA25683  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Kanamicina     |
| AAP74962  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Streptomicina  |
| AAS79146  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Gentamicina    |
| AAS79146  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Kanamicina     |
| AAT38947  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Streptomicina  |
| ABB99436  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Streptomicina  |
| ABO46016  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Streptomicina  |
| BAA06249  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Streptomicina  |
| BAA06249  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Kanamicina     |
| CAI40606  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Gentamicina    |
| CAI40606  | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Kanamicina     |
| YP_758627 | Transferasi | Nucleoside trifosfato + gentamicina <=> difosfato + 2'-
nucleotidilgentamicina                              | Lincomicina    |
| CAA27626  | Idrolasi    | Estere carbossilico + H(2)O <=> 1 alcol + 1 carbossilato
| Eritromicina   |
| CAJ29622  | Idrolasi    | Estere carbossilico + H(2)O <=> 1 alcol + 1 carbossilato
| Eritromicina   |
| AAA27471  | Translocasi | 2 ferredossina ridotta [Fe-Zn] + NAD(+) + H(+) + Na(+) <=> 2
ferredossina ossidata [Fe-Zn] + NADH + Na(+) | Tetraciclina   |
+-----------+-------------+-------------------------------------------------------------
---------------------------------------------+----------------+
28 rows in set (0,00 sec)
```

16a. Selezionare tutti gli antibiotici che intervengono nello stesso *pathway* dell'Eritromicina **(<u>Derived</u>)**

```
select ant.nome_a antibiotico from ant, subclass, atc, (select
pathway.path_id from pathway, atc, subclass, ant where
pathway.path_id=atc.path and atc.atc_id=subclass.atc_cl and
ant.subcl=subclass.sub_id and ant.nome_a="Eritromicina") as z
where z.path_id=atc.path and atc.atc_id=subclass.atc_cl and
ant.subcl=subclass.sub_id and ant.nome_a!="Streptomicina";
```

```
+----------------+
| antibiotico    |
+----------------+
| Tetraciclina   |
| Tigeciclina    |
| Cloramfenicolo |
| Eritromicina   |
| Lincomicina    |
| Gentamicina    |
| Kanamicina     |
+----------------+
7 rows in set (0,00 sec)
```

16b **(Alias)**

```
select x.nome_a from ant x, ant y, subclass a, subclass b, atc c,
atc d, pathway where x.subcl=a.sub_id and y.subcl=b.sub_id and
a.atc_cl=c.atc_id and b.atc_cl=d.atc_id and c.path=pathway.path_id
and d.path=pathway.path_id and y.nome_a="Eritromicina" and
x.nome_a!="Eritromicina";
```

```
+----------------+
| nome_a         |
+----------------+
| Tigeciclina    |
| Cloramfenicolo |
| Eritromicina   |
| Lincomicina    |
| Streptomicina  |
| Gentamicina    |
| Kanamicina     |
+----------------+
7 rows in set (0,00 sec)
```

17. Contare, per ogni famiglia batterica, quanti tipi di mutazioni di resistenza sono stati trovati, e mostrare le famiglie in ordine alfabetico.

```
select count(res) resistenze, fam.nome_f famiglie from fam, bat,
seq, resseq where resseq.seq=seq.seq_id and seq.bat=bat.bat_id and
fam.fam_id=bat.fam group by famiglie order by famiglie;
```

```
+------------+--------------------+
| resistenze | famiglie           |
+------------+--------------------+
|          1 | Aeromodanaceae     |
|          2 | Bacillaceae        |
|          1 | Bacterioidaceae    |
|         12 | Burkholderiaceae   |
|          1 | Corynebacteriaceae |
|         18 | Enterobacteriaceae |
|          1 | Lachnospiraceae    |
|          3 | Moraxellaceae      |
|          1 | Morganellaceae     |
|          1 | Mycobacteriaceae   |
|          1 | Pasteurellaceae    |
|         18 | Pseudomonaceae     |
|          2 | Staphylococcaceae  |
|          4 | Streptococcaceae   |
|          2 | Streptomycetaceae  |
|          2 | Vibrionaceae       |
+------------+--------------------+
16 rows in set (0,00 sec)
```

18. Trovare il peso molecolare medio (arrotondato) degli antibiotici di ogni classe principale.

```
select round(avg(mw)) "Peso molecolare (Da)", nome_atc "Classe di
antibiotici" from ant, subclass, atc where
ant.subcl=subclass.sub_id and subclass.atc_cl=atc.atc_id group by
nome_atc;
```

```
+----------------------+-----------------------------------------+
| Peso molecolare (Da) | Classe di antibiotici                   |
+----------------------+-----------------------------------------+
|                  515 | Tetracicline                            |
|                  323 | Amfenicoli                              |
|                  422 | Antibiotici beta lattamici, penicillina  |
|                  679 | Sulfonamidi e trimetroprim              |
|                  571 | Macrolidi, lincosamidi e streptogrammine |
|                  820 | Antibiotici aminoglucosidici            |
|                  331 | Chinoloni antibiotici                   |
+----------------------+-----------------------------------------+
7 rows in set (0,00 sec)
```

19. Selezionare gli id delle proteine la cui funzione coinvolge in qualche modo la traduzione, ordinandole in ordine decrescente.

```
select distinct prot proteina from funz, protfunz where
protfunz.funz=funz.funz_id and term like '%traduzione%' order by
proteina desc;
```

```
+----------+
| proteina |
+----------+
| CAD20560 |
| ABO87315 |
| ABO25866 |
| AAF01499 |
+----------+
4 rows in set (0,00 sec)
```

20. Trovare il numero di sequenze cromosomiche e la percentuale rispetto al totale delle sequenze.

```
select sum(seq.tipo='Cromosoma') as "chr_seqs",
round(sum(seq.tipo='Cromosoma') / count(seq.seq_id)*100) as
"chr_seqs/tot_seqs %" from seq;
```

```
+----------+---------------------+
| chr_seqs | chr_seqs/tot_seqs % |
+----------+---------------------+
|       32 |                  52 |
+----------+---------------------+
1 row in set (0,00 sec)
```

21. Selezionare il tipo di mutazione genetica più rappresentata nelle sequenze estratte da genomi plasmidici completi.

```
select count(mut.tipo) sequenze, mut.tipo from mut, res, resseq,
seq where res.mut=mut.tipo and resseq.res=res.res_id and
resseq.seq=seq.seq_id and seq.tipo='Plasmide' and compl='Y' group
by mut.tipo order by sequenze desc limit 1;
```

```
+----------+-----------------------+
| sequenze | tipo                  |
+----------+-----------------------+
|        4 | Mutazioni di splicing |
+----------+-----------------------+
1 row in set (0,00 sec)
```

22. Trovare su quante sequenze sono stati identificati almeno due tipi di resistenze diversi e quante sono le sequenze totali depositate nel database.

```
select count(*) sequenze, "sequenze con più di una resistenza" as
"" from (select seq sequenze from resseq group by seq having
count(res)>1) as z union select count(seq.seq_id),"sequenze
totali" as "" from seq;
```

```
+----------+-------------------------------------+
| sequenze |                                     |
+----------+-------------------------------------+
|        6 | sequenze con più di una resistenza  |
|       61 | sequenze totali                     |
+----------+-------------------------------------+
2 rows in set (0,00 sec)
```

10. QUERY IN ALGEBRA RELAZIONALE E CALCOLO RELAZIONALE

14. Selezionare le proteine che hanno un numero di residui compreso tra 100 e 200 e mostrare l'id delle proteine, il numero di residui, la sequenza genica da cui derivano e l'organismo a cui appartengono

$$\Pi_{prot_id,residui,seq,nome_sp}(BAT \mid X \mid_{bat_id=bat}(SEQ \mid X \mid_{seq_id=seq}(\sigma_{residui>=100 \wedge residui<=200}(PROT))))$$

16a. Selezionare tutti gli antibiotici che intervengono nello stesso *pathway* dell'Eritromicina

```
{a.nome_a | a(ant), a'(ant), s(subclass), s'(subclass), at(atc),
at'(atc), p(pathway) | a.subcl=s.sub_id ^ a'.subcl=s'.sub_id ^
s.atc_cl=at.atc_id ^ s'.atc_cl=at'.atc_id ^ at.path=p.path_id ^
at'.path=p.path_id ^ a'.nome_a="Eritromicina" ^ a.nome_a!="Eritromicina"}
```